

Ouvidoria Inteligente

Triagem Semântica de Manifestações Cidadãs — Relatório do Desafio Prático de NLP

1. Objetivo e visão geral

O protótipo substitui a triagem por palavras-chave da Ouvidoria por uma triagem semântica baseada em representações vetoriais, atacando os três problemas do enunciado: duplicatas não detectadas, temas relacionados não agrupados e perda de contexto em manifestações longas. O trabalho está dividido em três notebooks (análise comparativa, detecção de duplicatas e chunking) e um aplicativo Streamlit que reúne busca semântica, base completa, espaço vetorial e chunking.

Dados. Como o arquivo oficial não estava disponível durante o desenvolvimento, foi construído um *dataset de exemplo* que segue exatamente a especificação: 40 manifestações (M001-M040) com os campos `id`, `data`, `categoria_oficial` e `texto`; 5 categorias; 6 duplicatas semânticas (15%), registradas em `gabarito_duplicatas.json`; e 5 textos longos (674-705 caracteres). Os pares citados no enunciado (M003, M008, M017, M022, M031) contêm as frases indicadas. Também foram incluídos casos difíceis de propósito, como o mesmo local com problemas diferentes (M005 × M030) e o mesmo problema em outro local (M003 × M024). Todo o código lê o JSON, então basta trocar o arquivo e reexecutar.

2. Principais decisões

Decisão	Escolha	Motivo
Modelos de embedding	paraphrase-multilingual-MiniLM-L12-v2 (384 d) e paraphrase-multilingual-mpnet-base-v2 (768 d)	Multilíngues, recomendados para português. O BAAI/bge-small-pt-v1.5 sugerido não está disponível publicamente no Hugging Face.
Pré-processamento esparsos	minúsculas, sem acentos, stopwords do português	BoW/TF-IDF dependem de tokens idênticos; embeddings recebem o texto original.
Similaridade	cosseno com vetores normalizados	Com norma 1, o produto escalar é o cosseno — uma multiplicação de matrizes gera a matriz inteira.
Limiar de duplicata	0,75 com o mpnet	Faixa sem erros entre 0,71 e 0,77; precisão priorizada (fundir chamados diferentes é o erro mais caro).
Chunking	RecursiveCharacterTextSplitter, 300 caracteres, overlap 100, separadores por frase	Nenhuma frase cortada, cada chunk cabe nos 128 tokens do modelo, e 5/5 consultas de teste acertaram.
App	Streamlit com <code>st.cache_resource</code> (modelo) e <code>st.cache_data</code> (embeddings)	Trocar de aba ou de parâmetro não recalcula nada que já foi calculado.

3. Resultados

3.1 Entrega 1 — Esparsos × densos

Par	BoW	TF-IDF	MiniLM	mpnet
M003 × M017 — texto completo	0,36	0,26	0,68	0,77
M008 × M022 — texto completo	0,35	0,27	0,64	0,59
M008 × M031 — texto completo	0,00	0,00	0,14	0,14
M003 × M017 — frase do enunciado	0,00	0,00	0,29	0,59
M008 × M022 — frase do enunciado	0,00	0,00	0,29	0,29
M008 × M031 — frase do enunciado	0,00	0,00	0,01	0,17

Nos textos completos, BoW e TF-IDF até ordenam os pares corretamente, mas apenas porque os duplicados compartilham **nomes de lugar** ("Av. Brasil", "Rua XV", "Jardim América"). As palavras do problema (*buraco* × *esburacado*, *médico* × *clínico*) nunca coincidem. Nas frases curtas do enunciado, sem nomes próprios, as duas representações esparsas zeram, exatamente como o par sem relação. Os embeddings mantêm a separação (mpnet: 0,59 × 0,17), mas também mostram limites: a sigla "PSF" (Programa Saúde da Família) é pouco reconhecida, e os valores absolutos não são comparáveis entre representações, porque embeddings de textos sem relação ficam em torno de 0,1-0,4, e não em 0.

3.2 Entrega 2 — Duplicatas

Estratégia (mpnet)	Limiar	VP	FP	FN	Precisão	Revocação	F1
Fixo do enunciado	0,85	2	0	4	1,00	0,33	0,50
Dinâmico — percentil 90	0,51	6	72	0	0,08	1,00	0,14
Dinâmico — percentil 99	0,69	5	3	1	0,63	0,83	0,71
Calibrado (escolhido)	0,75	5	0	1	1,00	0,83	0,91
Híbrido: $\geq 0,75$ ou ($\geq 0,55$ e $TF-IDF \geq 0,20$)	—	6	1	0	0,86	1,00	0,92

O limiar de 0,85 é conservador demais: o MiniLM não encontra nenhuma duplicata, e o mpnet encontra apenas 2. O percentil 90 assume que 10% dos pares são duplicados, quando na verdade são 6 de 780 (0,8%). O mpnet separa melhor as classes (não há sobreposição entre 0,703 e 0,771), enquanto no MiniLM as distribuições se sobrepõem. O único falso negativo, M008 × M022 (0,59), é de novo o problema da sigla "PSF". Os pares não-duplicados mais próximos mostram dois padrões de risco: **mesmo local, problema diferente** (M005 × M030, a mesma escola, 0,70) e **mesmo tipo de problema, local diferente** (M013 × M036, descarte de lixo, 0,70). A regra híbrida recupera M008 × M022 pelo bairro em comum, mas foi ajustada nos mesmos 6 pares, então seu resultado é otimista.




Figura 1 — Distribuição das similaridades de todos os 780 pares (cinza) e das 6 duplicatas reais (verde).

3.3 Entrega 3 — Chunking

Configuração	Nº	Coesão	Fidelid.	Frases cortadas	Silh.	Top-1 na busca
A (150, 0), separadores padrão	25	0,44	0,65	76%	0,06	5/5
B (150, 50), padrão	35	0,58	0,65	80%	0,12	5/5
C (300, 60), padrão	15	0,67	0,79	60%	0,30	4/5
D (300, 60), por frase	15	0,54	0,76	0%	0,18	5/5
E (300, 100), por frase	16	0,56	0,75	0%	0,18	5/5
sem chunking	—	—	—	—	—	3/5

Nº = número de chunks; Coesão = cosseno médio entre chunks consecutivos; Fidelid. = cosseno médio chunk × documento; Silh. = silhueta por manifestação; Top-1 = consultas de teste em que a manifestação certa ficou em 1º.

Os dois modelos leem no máximo **128 tokens**, e as 5 manifestações longas têm entre 159 e 185 tokens. Sem chunking, o final das denúncias, justamente onde ficam os pedidos ("Pedimos rondas diárias...", "Solicito a ampliação das vagas..."), é descartado sem nenhum aviso. Nas consultas sobre esses detalhes, a manifestação correta caiu para 2º e 5º lugar. O **overlap aumenta a coesão** entre chunks consecutivos (0,44 → 0,58 de A para B), porque "costura" frases cortadas ("ponto de venda de" | "drogas"). Mas parte desse ganho é artificial, já que os chunks repetem texto, e o número de vetores cresce 40%. Como as manifestações não têm quebras de linha, os separadores padrão cortam no meio das frases; **trocar para separadores de pontuação** foi a mudança de maior impacto. Com separadores de frase, o overlap só é aplicado se couber uma frase inteira: em D (60) isso quase nunca acontece, e em E (100) a última frase curta se repete. No espaço 2D, 14 dos 16 chunks da configuração E têm como vizinho outro chunk da mesma manifestação. As exceções agrupam por *tipo de trecho*: os pedidos de contratação da UPA ficam perto dos da creche.




Figura 2 — Chunks das 5 manifestações longas em PCA e t-SNE (X = documento inteiro). Configuração E (acima): grupos compactos; configuração A (abaixo): chunks espalhados.

3.4 Entrega 4 — Aplicativo

O `app_ouvidoria.py` tem as quatro abas pedidas e uma barra lateral com seleção de modelo, top-k, limiar de duplicata, opção de busca por chunks e envio de outro JSON. A **Busca Semântica** mostra cartões coloridos (verde > 0,7, amarelo > 0,5, vermelho nos demais), destaca o chunk que motivou o resultado nos textos longos e avisa quando a descrição parece duplicar uma manifestação já registrada. A **Base Completa** tem filtros, a matriz de similaridade interativa e a lista de possíveis duplicatas. O **Espaço Vetorial** alterna entre PCA e t-SNE e calcula, por categoria, o percentual de vizinhos da mesma categoria e a silhueta. O **Chunking** compara três estratégias, destaca o trecho de overlap, avisa quando o texto passa do limite de tokens e mostra a similaridade entre chunks, sua posição no mapa e os próprios vetores.

Clusters x categorias: saúde e educação formam grupos claros, com 86–88% de vizinhos na mesma categoria. Já infraestrutura, meio ambiente e segurança se misturam numa região "urbana": segurança tem só 57% (mpnet), porque "praça sem policiamento" e "rua escura" são, para o cidadão, o mesmo problema. A silhueta por categoria é baixa ($\approx 0,11$). Os embeddings agrupam pelo assunto concreto, enquanto as categorias refletem a secretaria responsável; para rotear, um classificador supervisionado seria mais adequado que o simples agrupamento.

4. Dificuldades

- **Dataset ausente:** foi necessário construir um dataset fiel à especificação, com gabarito de duplicatas e casos difíceis, sem enviesar os resultados a favor de um método.
- **Modelo sugerido indisponível:** o BAAI/bge-small-pt-v1.5 não existe publicamente; ele foi substituído pelo mpnet multilíngue.
- **Truncamento silencioso:** o sentence-transformers corta textos acima de 128 tokens sem avisar. Só foi percebido ao medir o número de tokens, e passou a ser o principal argumento a favor do chunking.
- **Separadores do splitter:** os separadores padrão pressupõem quebras de linha. Em texto corrido, cortam no meio das frases, e o overlap interage de forma pouco intuitiva com separadores de frase.

- **Calibração com poucos positivos:** com 6 duplicatas, qualquer limiar tem alta variância, e regras mais elaboradas (como a híbrida) correm o risco de sobreajuste.

5. Aprendizados

- Similaridade esparsa mede coincidência de *palavras*, não de significado; quando parece funcionar, vale checar *quais* termos sustentam o resultado.
- Cossenos de representações diferentes vivem em escalas diferentes. Limiares precisam ser calibrados por modelo e comparados pela posição na distribuição, não pelo valor absoluto.
- Limiares devem refletir o custo dos erros e a taxa esperada de positivos. Um percentil genérico pode gerar dezenas de falsos alarmes.
- Métricas agregadas (coesão, silhueta) não capturam legibilidade. Ler os chunks e testar a busca de verdade foi decisivo para escolher a configuração.
- Na prática, a melhor triagem combina as abordagens: embeddings para o significado, termos exatos (endereço, unidade) para confirmar se é o mesmo local, e revisão humana na zona cinzenta.

6. Como executar

`pip install -r requirements.txt`; abrir os notebooks no Jupyter e executar todas as células; para o app: `streamlit run app_ouvidoria.py`. Na primeira execução, os modelos (~0,5 GB e ~1,1 GB) são baixados do Hugging Face.